Descubrimiento de información en textos

Tarea del tema 6: Clustering

Gabriel Vázquez Torres

Descubrimiento de información en textos

Tarea del tema 6: Clustering

Descripción de los datasets

Los dataset utilizados han sido re0.mat y re1.mat, que son los propuestos en el enunciado de este trabajo.

- El fichero re0.mat tiene: 1504 documentos, 2886 términos y 13 clases.
- El fichero re1.mat tiene: 1657 documentos, 3758 términos y 25 clases.

A continuación, se detallan las pruebas realizadas con distintos algoritmos, funciones de similitud y funciones de criterio a estos dos ficheros.

Pruebas realizadas y análisis de los resultados

He utilizado la versión del programa CLUTO para Linux, creando un script que generaba los ficheros .txt que me interesaban, acorde con la información que deseaba guardar para realizar su posterior estudio.

El script se llama ejecutor.sh y contiene el siguiente código:

Sin estadísticas

```
#!/bin/bash

./vcluster -clmethod='agglo' -sim='cos' -crfun='i1' re0.mat 10 > r0-agglo-cos-i1.txt

./vcluster -clmethod='agglo' -sim='cos' -crfun='i2' re0.mat 10 > r0-agglo-cos-i2.txt

./vcluster -clmethod='graph' -sim='dist' -crfun='i1' re0.mat 10 > r0-graph-dist-i1.txt

./vcluster -clmethod='graph' -sim='jacc' -crfun='i1' re0.mat 10 > r0-graph-jacc-i1.txt

./vcluster -clmethod='agglo' -sim='cos' -crfun='i1' re1.mat 10 > r1-agglo-cos-i1.txt

./vcluster -clmethod='agglo' -sim='cos' -crfun='i2' re1.mat 10 > r1-agglo-cos-i2.txt

./vcluster -clmethod='graph' -sim='dist' -crfun='i1' re1.mat 10 > r1-graph-dist-i1.txt

./vcluster -clmethod='graph' -sim='jacc' -crfun='i1' re1.mat 10 > r1-graph-jacc-i1.txt
```

Con estadísticas

```
./vcluster -clmethod='agglo' -sim='cos' -crfun='i1' -rclassfile=estadisticas/re0.mat.rclass re0.mat 10 >
r0-

agglo-cos-i1-EST.txt

./vcluster -clmethod='agglo' -sim='cos' -crfun='i2' -rclassfile=estadisticas/re0.mat.rclass re0.mat 10 >
r0-

agglo-cos-i2-EST.txt

./vcluster -clmethod='graph' -sim='dist' -crfun='i1' -rclassfile=estadisticas/re0.mat.rclass re0.mat 10 >

r0-graph-dist-i1-EST.txt

./vcluster -clmethod='graph' -sim='jacc' -crfun='i1' -rclassfile=estadisticas/re0.mat.rclass re0.mat 10 >

r0-graph-jacc-i1-EST.txt
```

./vcluster -clmethod='agglo' -sim='cos' -crfun='i1' -rclassfile=estadisticas/re1.mat.rclass re1.mat 10 > r1-

agglo-cos-i1-EST.txt

./vcluster -clmethod='agglo' -sim='cos' -crfun='i2' -rclassfile=estadisticas/re1.mat.rclass re1.mat 10 > r1-

agglo-cos-i2-EST.txt

./vcluster -clmethod='graph' -sim='dist' -crfun='i1' -rclassfile=estadisticas/re1.mat.rclass re1.mat 10 >

r1-graph-dist-i1-EST.txt

./vcluster -clmethod='graph' -sim='jacc' -crfun='i1' -rclassfile=estadisticas/re1.mat.rclass re1.mat 10 >

r1-graph-jacc-i1-EST.txt

Siguiendo el orden del script, a continuación mostraré las salidas obtenidas y haré un breve análisis, explicando distintos elementos.

VCluster aplicado al fichero re0.mat

Con un algoritmo aglomerativo, función de similitud cosine y función de criterio i1

Línea de comando:

./vcluster -clmethod='agglo' -sim='cos' -crfun='i1' re0.mat 10

```
*******************************************************************************
vcluster (CLUTO 2.1.1) Copyright 2001-03, Regents of the University of Minnesota

Matrix Information ------------------------------------------------------------
  Name: re1.mat, #Rows: 1657, #Columns: 3758, #NonZeros: 87328

Options -----------------------------------------------------------------------
  CLMethod=GRAPH, CRfun=Cut, SimFun=ExtJaccard, #Clusters: 10
  RowModel=None, ColModel=IDF, GrModel=SY-DIR, NNbrs=40
  Colprune=1.00, EdgePrune=-1.00, VtxPrune=-1.00, MinComponent=5
  CSType=Best, AggloFrom=0, AggloCRFun=SLINK_W, NTrials=10, NIter=10

Solution ----------------------------------------------------------------------

------------------------------------------------------------------------
10-way clustering: [Cut=3.17e+03] [1657 of 1657]
------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  |
------------------------------------------------------------------------
  0    90 +0.050 +0.027 +0.000 +0.000 |
  1    91 +0.049 +0.025 +0.000 +0.000 |
  2    90 +0.046 +0.034 +0.000 +0.000 |
  3   134 +0.030 +0.018 +0.000 +0.000 |
  4   148 +0.022 +0.018 +0.000 +0.000 |
  5   123 +0.020 +0.013 +0.000 +0.000 |
  6   168 +0.015 +0.010 +0.000 +0.000 |
  7   171 +0.015 +0.012 +0.001 +0.000 |
  8   244 +0.010 +0.006 +0.000 +0.000 |
  9   398 +0.009 +0.005 +0.000 +0.000 |
------------------------------------------------------------------------

Timing Information ------------------------------------------------------------
   I/O:                                0.072 sec
   Clustering:                         0.716 sec
   Reporting:                          0.008 sec
*******************************************************************************
```

En primer lugar, comentar de forma muy breve el significado de cada columna:

◎ cid: Representa la id de cada cluster creado a partir del documento que hemos querido empaquetar mediante esta técnica de clustering.

◎ Size: cantidad de objetos que contiene cada uno de los 10 clusters que hemos creado.

◎ ISim: Número que muestra la media de similitud entre los objetos del cluster.

◎ ISdev: Media de la desviación de las similitudes entre objetos del cluster.

◎ ESim: Similitud de los objetos de cada cluster y del resto.

◎ ESdev: Desviación de las similitudes de los objetos de cada cluster y del resto.

Aplicando la siguiente línea de comando:

./vcluster -clmethod='agglo' -sim='cos' -crfun='i1' -rclassfile=estadisticas/re0.mat.rclass re0.mat 10

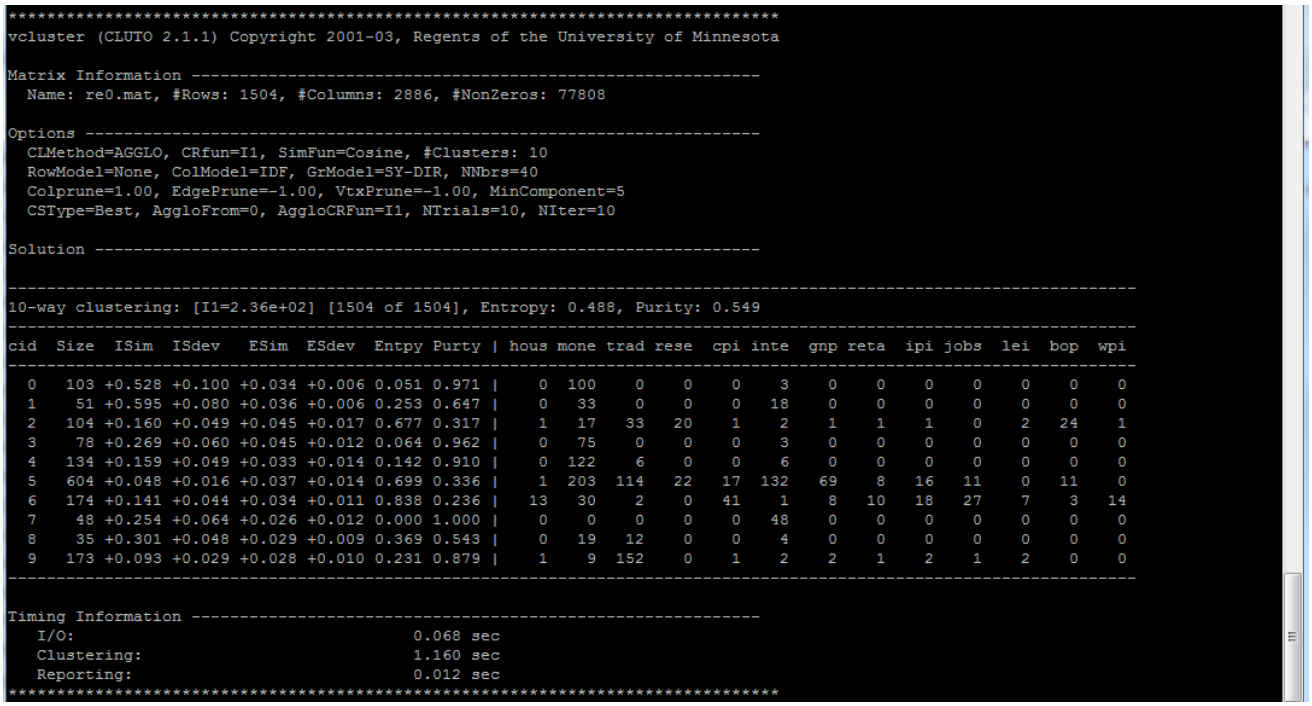

```
*******************************************************************************
vcluster (CLUTO 2.1.1) Copyright 2001-03, Regents of the University of Minnesota

Matrix Information ------------------------------------------------------------
  Name: re0.mat, #Rows: 1504, #Columns: 2886, #NonZeros: 77808

Options -----------------------------------------------------------------------
  CLMethod=AGGLO, CRfun=I1, SimFun=Cosine, #Clusters: 10
  RowModel=None, ColModel=IDF, GrModel=SY-DIR, NNbrs=40
  Colprune=1.00, EdgePrune=-1.00, VtxPrune=-1.00, MinComponent=5
  CSType=Best, AggloFrom=0, AggloCRFun=I1, NTrials=10, NIter=10

Solution ----------------------------------------------------------------------

------------------------------------------------------------------------------------------------------------------------
10-way clustering: [I1=2.36e+02] [1504 of 1504], Entropy: 0.488, Purity: 0.549
------------------------------------------------------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  Entpy Purty | hous mone trad rese  cpi inte  gnp reta  ipi jobs  lei  bop  wpi
------------------------------------------------------------------------------------------------------------------------
  0   103 +0.528 +0.100 +0.034 +0.006 0.051 0.971 |    0  100    0    0    0    3    0    0    0    0    0    0    0
  1    51 +0.595 +0.080 +0.036 +0.006 0.253 0.647 |    0   33    0    0    0   18    0    0    0    0    0    0    0
  2   104 +0.160 +0.049 +0.045 +0.017 0.677 0.317 |    1   17   33   20    1    2    1    1    1    0    2   24    1
  3    78 +0.269 +0.060 +0.045 +0.012 0.064 0.962 |    0   75    0    0    0    3    0    0    0    0    0    0    0
  4   134 +0.159 +0.049 +0.033 +0.014 0.142 0.910 |    0  122    6    0    0    6    0    0    0    0    0    0    0
  5   604 +0.048 +0.016 +0.037 +0.014 0.699 0.336 |    1  203  114   22   17  132   69    8   16   11    0   11    0
  6   174 +0.141 +0.044 +0.034 +0.011 0.838 0.236 |   13   30    2    0   41    1    8   10   18   27    7    3   14
  7    48 +0.254 +0.064 +0.026 +0.012 0.000 1.000 |    0    0    0    0    0   48    0    0    0    0    0    0    0
  8    35 +0.301 +0.048 +0.029 +0.009 0.369 0.543 |    0   19   12    0    0    4    0    0    0    0    0    0    0
  9   173 +0.093 +0.029 +0.028 +0.010 0.231 0.879 |    1    9  152    0    1    2    2    1    2    1    2    0    0
------------------------------------------------------------------------------------------------------------------------

Timing Information ------------------------------------------------------------
   I/O:                          0.068 sec
   Clustering:                   1.160 sec
   Reporting:                    0.012 sec
*******************************************************************************
```

Se obtienen 2 columnas más de información:

◎ Entpy (Entropy): Muestra el índice de objetos de distinto tipo empaquetados en un clúster.

◎ Purty (Purity): Nos da un valor que varía entre 0 y 1 en función de la similitud de la clase de los objetos empaquetados en un clúster concreto.

Sabiendo esto, en este primer caso se puede destacar que:

- El clúster 7 realiza un empaquetado perfecto: posee una pureza de valor 1 debido a que contiene 48 objetos que son del mismo tipo 'inte'.

- Los clústers 0, 3 y 4 tienen también un alto nivel de pureza mientras que por ejemplo, el clúster 6 tiene muchos paquetes de distinto tipo, con lo que la pureza es bastante pequeña.

Con un algoritmo aglomerativo, función de similitud cosine y función de criterio i2

Línea de comando:

./vcluster -clmethod='agglo' -sim='cos' -crfun='i2' re0.mat 10

```
*******************************************************************************
vcluster (CLUTO 2.1.1) Copyright 2001-03, Regents of the University of Minnesota

Matrix Information ------------------------------------------------------------
  Name: re0.mat, #Rows: 1504, #Columns: 2886, #NonZeros: 77808

Options -----------------------------------------------------------------------
  CLMethod=AGGLO, CRfun=I2, SimFun=Cosine, #Clusters: 10
  RowModel=None, ColModel=IDF, GrModel=SY-DIR, NNbrs=40
  Colprune=1.00, EdgePrune=-1.00, VtxPrune=-1.00, MinComponent=5
  CSType=Best, AggloFrom=0, AggloCRFun=I2, NTrials=10, NIter=10

Solution ----------------------------------------------------------------------

------------------------------------------------------------------------
10-way clustering: [I2=5.47e+02] [1504 of 1504]
------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  |
------------------------------------------------------------------------
  0   104 +0.512 +0.115 +0.034 +0.005 |
  1   255 +0.060 +0.021 +0.033 +0.013 |
  2   317 +0.093 +0.034 +0.034 +0.013 |
  3   214 +0.081 +0.027 +0.033 +0.015 |
  4    57 +0.548 +0.095 +0.036 +0.007 |
  5    96 +0.199 +0.045 +0.034 +0.015 |
  6    82 +0.194 +0.058 +0.038 +0.014 |
  7   176 +0.091 +0.029 +0.027 +0.010 |
  8    74 +0.168 +0.036 +0.043 +0.013 |
  9   129 +0.136 +0.052 +0.045 +0.015 |
------------------------------------------------------------------------

Timing Information ------------------------------------------------------------
   I/O:                                 0.068 sec
   Clustering:                          1.200 sec
   Reporting:                           0.008 sec
*******************************************************************************
```

Aplicando la siguiente línea de comando:

./vcluster -clmethod='agglo' -sim='cos' -crfun='i2' -rclassfile=estadisticas/re0.mat.rclass re0.mat 10

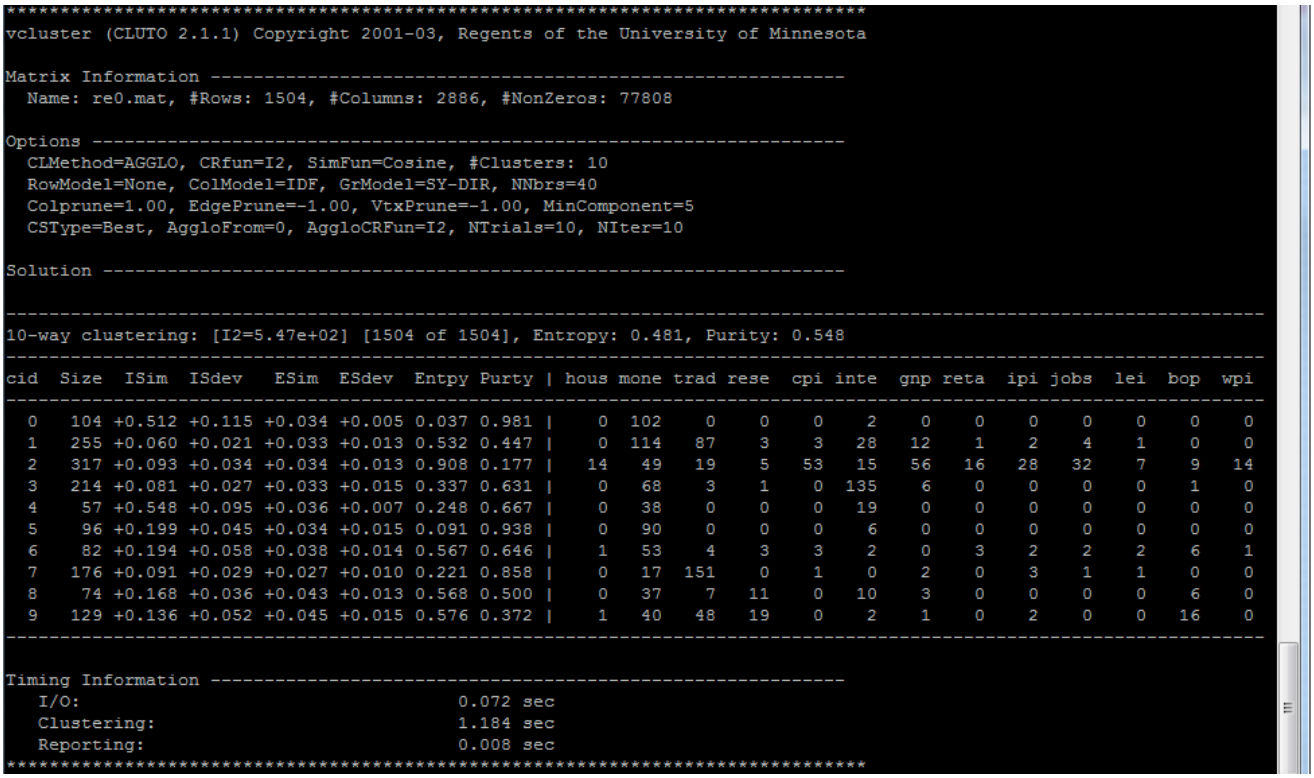

```
*******************************************************************************
vcluster (CLUTO 2.1.1) Copyright 2001-03, Regents of the University of Minnesota

Matrix Information ------------------------------------------------------------
  Name: re0.mat, #Rows: 1504, #Columns: 2886, #NonZeros: 77808

Options -----------------------------------------------------------------------
  CLMethod=AGGLO, CRfun=I2, SimFun=Cosine, #Clusters: 10
  RowModel=None, ColModel=IDF, GrModel=SY-DIR, NNbrs=40
  Colprune=1.00, EdgePrune=-1.00, VtxPrune=-1.00, MinComponent=5
  CSType=Best, AggloFrom=0, AggloCRFun=I2, NTrials=10, NIter=10

Solution ----------------------------------------------------------------------

------------------------------------------------------------------------------------------------------------------------
10-way clustering: [I2=5.47e+02] [1504 of 1504], Entropy: 0.481, Purity: 0.548
------------------------------------------------------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  Entpy Purty | hous mone trad rese  cpi inte  gnp reta  ipi jobs  lei  bop  wpi
------------------------------------------------------------------------------------------------------------------------
  0   104 +0.512 +0.115 +0.034 +0.005 0.037 0.981 |    0  102    0    0    0    2    0    0    0    0    0    0    0
  1   255 +0.060 +0.021 +0.033 +0.013 0.532 0.447 |    0  114   87    3    3   28   12    1    2    4    1    0    0
  2   317 +0.093 +0.034 +0.034 +0.013 0.908 0.177 |   14   49   19    5   53   15   56   16   28   32    7    9   14
  3   214 +0.081 +0.027 +0.033 +0.015 0.337 0.631 |    0   68    3    1    0  135    6    0    0    0    0    1    0
  4    57 +0.548 +0.095 +0.036 +0.007 0.248 0.667 |    0   38    0    0    0   19    0    0    0    0    0    0    0
  5    96 +0.199 +0.045 +0.034 +0.015 0.091 0.938 |    0   90    0    0    0    6    0    0    0    0    0    0    0
  6    82 +0.194 +0.058 +0.038 +0.014 0.567 0.646 |    1   53    4    3    3    2    0    3    2    2    2    6    1
  7   176 +0.091 +0.029 +0.027 +0.010 0.221 0.858 |    0   17  151    0    1    0    2    0    3    1    1    0    0
  8    74 +0.168 +0.036 +0.043 +0.013 0.568 0.500 |    0   37    7   11    0   10    3    0    0    0    0    6    0
  9   129 +0.136 +0.052 +0.045 +0.015 0.576 0.372 |    1   40   48   19    0    2    1    0    2    0    0   16    0
------------------------------------------------------------------------------------------------------------------------

Timing Information ------------------------------------------------------------
   I/O:                                 0.072 sec
   Clustering:                          1.184 sec
   Reporting:                           0.008 sec
*******************************************************************************
```

A diferencia de los parámetros usados en el punto anterior, aplicando estos criterios se observa que la Pureza general (que anteriormente era de 0.549) es prácticamente igual a la obtenida con esta variación, habiendo utilizado la función de criterio i2, que ha sido de 0.548.

Sin embargo, los clústers que se han formado son totalmente distintos, destacan el 0 y el 5 que tienen una pureza muy alta, pero sin embargo en el resto de clústers, en lugar de tener 4 clústers con una pureza alta y 6 con pureza algo más baja, tenemos una pureza más o menos acorde con la media general en cada clúster.

Con un algoritmo de separación, función de similitud de distancia euclidea y función de criterio i1

Línea de comando:

./vcluster -clmethod='graph' -sim='dist' -crfun='i1' re0.mat 10

```
*******************************************************************************
vcluster (CLUTO 2.1.1) Copyright 2001-03, Regents of the University of Minnesota

Matrix Information ------------------------------------------------------------
  Name: re0.mat, #Rows: 1504, #Columns: 2886, #NonZeros: 77808

Options -----------------------------------------------------------------------
  CLMethod=GRAPH, CRfun=Cut, SimFun=EuclDist, #Clusters: 10
  RowModel=None, ColModel=IDF, GrModel=SY-DIR, NNbrs=40
  Colprune=1.00, EdgePrune=-1.00, VtxPrune=-1.00, MinComponent=5
  CSType=Best, AggloFrom=0, AggloCRFun=SLINK_W, NTrials=10, NIter=10

Solution ----------------------------------------------------------------------

------------------------------------------------------------------------
29-way clustering: [Cut=3.08e+03] [458 of 1504]
------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  |
------------------------------------------------------------------------
  0    20 +0.934 +0.102 +0.000 +0.000 |
  1     7 +0.995 +0.003 +0.000 +0.000 |
  2     7 +0.982 +0.004 +0.000 +0.000 |
  3     6 +0.997 +0.001 +0.000 +0.000 |
  4     5 +0.997 +0.002 +0.000 +0.000 |
  5     9 +0.881 +0.159 +0.000 +0.000 |
  6    17 +0.804 +0.201 +0.014 +0.008 |
  7    37 +0.689 +0.213 +0.005 +0.010 |
  8    11 +0.672 +0.200 +0.023 +0.018 |
  9     5 +0.666 +0.261 +0.000 +0.000 |
 10    48 +0.539 +0.193 +0.009 +0.012 |
 11     6 +0.598 +0.219 +0.000 +0.000 |
 12     5 +0.593 +0.218 +0.000 +0.000 |
 13    36 +0.484 +0.233 +0.000 +0.000 |
 14    22 +0.491 +0.234 +0.002 +0.007 |
 15    25 +0.479 +0.220 +0.026 +0.019 |
 16    11 +0.471 +0.236 +0.000 +0.000 |
 17     5 +0.474 +0.179 +0.000 +0.000 |
 18    15 +0.361 +0.167 +0.003 +0.003 |
 19     6 +0.391 +0.214 +0.000 +0.000 |
 20     6 +0.386 +0.214 +0.000 +0.000 |
 21     6 +0.361 +0.167 +0.000 +0.000 |
 22    15 +0.304 +0.141 +0.001 +0.001 |
 23    14 +0.307 +0.100 +0.006 +0.005 |
 24     7 +0.319 +0.129 +0.000 +0.000 |
 25    35 +0.280 +0.157 +0.010 +0.014 |
 26     8 +0.299 +0.166 +0.000 +0.000 |
 27    36 +0.196 +0.122 +0.003 +0.004 |
 28    28 +0.089 +0.066 +0.000 +0.000 |
------------------------------------------------------------------------

Timing Information ------------------------------------------------------------
   I/O:                                 0.060 sec
   Clustering:                          0.340 sec
   Reporting:                          -0.000 sec
*******************************************************************************
```

Comando:

./vcluster -clmethod='graph' -sim='dist' -crfun='i1' -rclassfile=estadisticas/re0.mat.rclass

re0.mat 10

```
29-way clustering: [Cut=3.08e+03] [458 of 1504], Entropy: 0.264, Purity: 0.723

cid  Size  ISim  ISdev   ESim  ESdev  Entpy Purty | hous mone trad rese  cpi inte  gnp reta  ipi jobs  lei  bop  wpi
  0    20 +0.934 +0.102 +0.000 +0.000 0.000 1.000 |    0   20    0    0    0    0    0    0    0    0    0    0    0
  1     7 +0.995 +0.003 +0.000 +0.000 0.160 0.857 |    0    6    0    0    0    1    0    0    0    0    0    0    0
  2     7 +0.982 +0.004 +0.000 +0.000 0.000 1.000 |    0    7    0    0    0    0    0    0    0    0    0    0    0
  3     6 +0.997 +0.001 +0.000 +0.000 0.000 1.000 |    0    0    0    0    0    6    0    0    0    0    0    0    0
  4     5 +0.997 +0.002 +0.000 +0.000 0.000 1.000 |    0    5    0    0    0    0    0    0    0    0    0    0    0
  5     9 +0.881 +0.159 +0.000 +0.000 0.000 1.000 |    0    9    0    0    0    0    0    0    0    0    0    0    0
  6    17 +0.804 +0.201 +0.014 +0.008 0.000 1.000 |    0   17    0    0    0    0    0    0    0    0    0    0    0
  7    37 +0.689 +0.213 +0.005 +0.010 0.000 1.000 |    0   37    0    0    0    0    0    0    0    0    0    0    0
  8    11 +0.672 +0.200 +0.023 +0.018 0.234 0.818 |    0    9    1    0    0    0    0    0    0    1    0    0    0
  9     5 +0.666 +0.261 +0.000 +0.000 0.000 1.000 |    0    5    0    0    0    0    0    0    0    0    0    0    0
 10    48 +0.539 +0.193 +0.009 +0.012 0.185 0.854 |    0   41    0    1    0    6    0    0    0    0    0    0    0
 11     6 +0.598 +0.219 +0.000 +0.000 0.338 0.667 |    0    4    1    0    0    1    0    0    0    0    0    0    0
 12     5 +0.593 +0.218 +0.000 +0.000 0.000 1.000 |    0    0    0    0    0    5    0    0    0    0    0    0    0
 13    36 +0.484 +0.233 +0.000 +0.000 0.261 0.611 |    0   22    0    0    0   14    0    0    0    0    0    0    0
 14    22 +0.491 +0.234 +0.002 +0.007 0.000 1.000 |    0   22    0    0    0    0    0    0    0    0    0    0    0
 15    25 +0.479 +0.220 +0.026 +0.019 0.736 0.360 |    0    1    0    1    4    9    3    0    3    2    0    1    1
 16    11 +0.471 +0.236 +0.000 +0.000 0.000 1.000 |    0    0    0    0    0   11    0    0    0    0    0    0    0
 17     5 +0.474 +0.179 +0.000 +0.000 0.000 1.000 |    0    0    5    0    0    0    0    0    0    0    0    0    0
 18    15 +0.361 +0.167 +0.003 +0.003 0.386 0.467 |    0    6    7    0    0    2    0    0    0    0    0    0    0
 19     6 +0.391 +0.214 +0.000 +0.000 0.394 0.500 |    0    0    3    2    0    0    0    0    0    0    0    1    0
 20     6 +0.386 +0.214 +0.000 +0.000 0.394 0.500 |    0    0    3    1    0    0    0    0    0    0    0    2    0
 21     6 +0.361 +0.167 +0.000 +0.000 0.176 0.833 |    0    0    1    0    0    0    0    0    0    0    0    5    0
 22    15 +0.304 +0.141 +0.001 +0.001 0.493 0.333 |    0    5    1    0    0    0    5    0    0    0    0    4    0
 23    14 +0.307 +0.100 +0.006 +0.005 0.481 0.500 |    0    2    0    3    0    7    0    0    0    2    0    0    0
 24     7 +0.319 +0.129 +0.000 +0.000 0.000 1.000 |    0    7    0    0    0    0    0    0    0    0    0    0    0
 25    35 +0.280 +0.157 +0.010 +0.014 0.179 0.829 |    0   29    0    0    0    6    0    0    0    0    0    0    0
 26     8 +0.299 +0.166 +0.000 +0.000 0.422 0.375 |    0    3    0    2    0    3    0    0    0    0    0    0    0
 27    36 +0.196 +0.122 +0.003 +0.004 0.863 0.194 |    1    3    5    2    2    7    0    3    2    0    3    7    1
 28    28 +0.089 +0.066 +0.000 +0.000 0.432 0.536 |    0    0    0    0   15    0    0    1    0    5    0    0    7

Timing Information --------------------------------------------------------
   I/O:                         0.036 sec
   Clustering:                  0.284 sec
   Reporting:                  -0.000 sec
********************************************************************************
```

En esta aplicación, se observa que el programa genera un mayor número de clústers, con u menor número de objetos almacenados en cada uno, pero con una pureza bastante alta, la media es de 0.723, frente a 0.548 y 0.549 de la anterior aplicación.

Esto indica que siguiendo un algoritmo de separación y una función de selección mediante distancia euclidea, se obtiene un mejor empaquetado mediante clustering.

Con un algoritmo de separación, función de similitud del coeficiente de Jaccard y función de criterio i1

Línea de comando:

./vcluster -clmethod='graph' -sim='jacc' -crfun='i1' re0.mat 10

```
*******************************************************************************
vcluster (CLUTO 2.1.1) Copyright 2001-03, Regents of the University of Minnesota

Matrix Information ------------------------------------------------------------
  Name: re0.mat, #Rows: 1504, #Columns: 2886, #NonZeros: 77808

Options -----------------------------------------------------------------------
  CLMethod=GRAPH, CRfun=Cut, SimFun=ExtJaccard, #Clusters: 10
  RowModel=None, ColModel=IDF, GrModel=SY-DIR, NNbrs=40
  Colprune=1.00, EdgePrune=-1.00, VtxPrune=-1.00, MinComponent=5
  CSType=Best, AggloFrom=0, AggloCRFun=SLINK_W, NTrials=10, NIter=10

Solution ----------------------------------------------------------------------

------------------------------------------------------------------------
10-way clustering: [Cut=4.06e+03] [1502 of 1504]
------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  |
------------------------------------------------------------------------
  0    20 +0.693 +0.097 +0.001 +0.001 |
  1    57 +0.347 +0.142 +0.000 +0.001 |
  2    23 +0.287 +0.118 +0.001 +0.001 |
  3    97 +0.101 +0.084 +0.000 +0.000 |
  4   140 +0.032 +0.020 +0.001 +0.000 |
  5   111 +0.031 +0.018 +0.000 +0.000 |
  6   171 +0.022 +0.014 +0.001 +0.000 |
  7   245 +0.015 +0.008 +0.000 +0.000 |
  8   239 +0.012 +0.008 +0.000 +0.000 |
  9   399 +0.010 +0.005 +0.001 +0.001 |
------------------------------------------------------------------------

Timing Information ------------------------------------------------------------
   I/O:                                 0.068 sec
   Clustering:                          0.660 sec
   Reporting:                           0.004 sec
*******************************************************************************
```

Comando:

./vcluster -clmethod='graph' -sim='jacc' -crfun='i1' -rclassfile=estadisticas/re0.mat.rclass

re0.mat 10

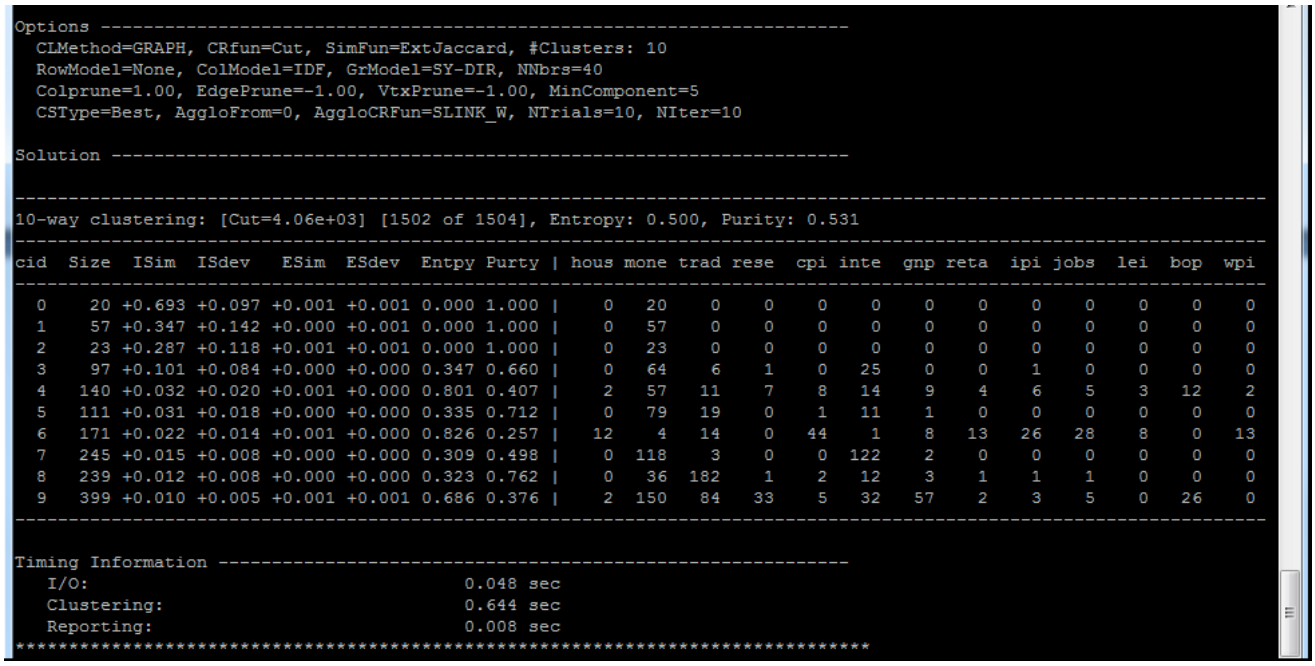

```
Options ----------------------------------------------------------------------
  CLMethod=GRAPH, CRfun=Cut, SimFun=ExtJaccard, #Clusters: 10
  RowModel=None, ColModel=IDF, GrModel=SY-DIR, NNbrs=40
  Colprune=1.00, EdgePrune=-1.00, VtxPrune=-1.00, MinComponent=5
  CSType=Best, AggloFrom=0, AggloCRFun=SLINK_W, NTrials=10, NIter=10

Solution ---------------------------------------------------------------------

-------------------------------------------------------------------------------------------------------------------------
10-way clustering: [Cut=4.06e+03] [1502 of 1504], Entropy: 0.500, Purity: 0.531
-------------------------------------------------------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  Entpy Purty | hous mone trad rese  cpi inte  gnp reta  ipi jobs  lei  bop  wpi
-------------------------------------------------------------------------------------------------------------------------
  0    20 +0.693 +0.097 +0.001 +0.001 0.000 1.000 |    0   20    0    0    0    0    0    0    0    0    0    0    0
  1    57 +0.347 +0.142 +0.000 +0.001 0.000 1.000 |    0   57    0    0    0    0    0    0    0    0    0    0    0
  2    23 +0.287 +0.118 +0.001 +0.001 0.000 1.000 |    0   23    0    0    0    0    0    0    0    0    0    0    0
  3    97 +0.101 +0.084 +0.000 +0.000 0.347 0.660 |    0   64    6    1    0   25    0    0    1    0    0    0    0
  4   140 +0.032 +0.020 +0.001 +0.000 0.801 0.407 |    2   57   11    7    8   14    9    4    6    5    3   12    2
  5   111 +0.031 +0.018 +0.000 +0.000 0.335 0.712 |    0   79   19    0    1   11    1    0    0    0    0    0    0
  6   171 +0.022 +0.014 +0.001 +0.000 0.826 0.257 |   12    4   14    0   44    1    8   13   26   28    8    0   13
  7   245 +0.015 +0.008 +0.000 +0.000 0.309 0.498 |    0  118    3    0    0  122    2    0    0    0    0    0    0
  8   239 +0.012 +0.008 +0.000 +0.000 0.323 0.762 |    0   36  182    1    2   12    3    1    1    1    0    0    0
  9   399 +0.010 +0.005 +0.001 +0.001 0.686 0.376 |    2  150   84   33    5   32   57    2    3    5    0   26    0
-------------------------------------------------------------------------------------------------------------------------

Timing Information -----------------------------------------------------------
   I/O:                                 0.048 sec
   Clustering:                          0.644 sec
   Reporting:                           0.008 sec
*******************************************************************************
```

En esta aplicación, se observa que el programa genera los clústers con una pureza más alta y con un menor número de objetos insertados en los primeros clústeres, pero en los últimos clústers almacena un mayor número de objetos y además de distinto tipo, haciendo que la pureza general sea peor que las anteriores.

Esto es producido por el cambio en la función de similitud.

VCluster aplicado al fichero re1.mat

Con un algoritmo aglomerativo, función de similitud cosine y función de criterio i1

Línea de comando:

./vcluster -clmethod='agglo' -sim='cos' -crfun='i1' re1.mat 10

```
*******************************************************************************
vcluster (CLUTO 2.1.1) Copyright 2001-03, Regents of the University of Minnesota

Matrix Information ------------------------------------------------------------
  Name: re1.mat, #Rows: 1657, #Columns: 3758, #NonZeros: 87328

Options -----------------------------------------------------------------------
  CLMethod=AGGLO, CRfun=I1, SimFun=Cosine, #Clusters: 10
  RowModel=None, ColModel=IDF, GrModel=SY-DIR, NNbrs=40
  Colprune=1.00, EdgePrune=-1.00, VtxPrune=-1.00, MinComponent=5
  CSType=Best, AggloFrom=0, AggloCRFun=I1, NTrials=10, NIter=10

Solution ----------------------------------------------------------------------

------------------------------------------------------------------------
10-way clustering: [I1=1.52e+02] [1657 of 1657]
------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  |
------------------------------------------------------------------------
  0    75 +0.223 +0.059 +0.024 +0.008 |
  1   105 +0.174 +0.043 +0.025 +0.009 |
  2    70 +0.213 +0.055 +0.016 +0.006 |
  3    44 +0.271 +0.048 +0.020 +0.009 |
  4    29 +0.487 +0.103 +0.021 +0.008 |
  5   325 +0.061 +0.018 +0.023 +0.008 |
  6    72 +0.203 +0.043 +0.028 +0.008 |
  7    32 +0.325 +0.047 +0.022 +0.005 |
  8    60 +0.166 +0.046 +0.017 +0.005 |
  9   845 +0.025 +0.008 +0.022 +0.010 |
------------------------------------------------------------------------

Timing Information ------------------------------------------------------------
   I/O:                                  0.076 sec
   Clustering:                           1.424 sec
   Reporting:                            0.008 sec
*******************************************************************************
```

Aplicando la siguiente línea de comando:

./vcluster -clmethod='agglo' -sim='cos' -crfun='i1' -rclassfile=estadisticas/re1.mat.rclass re1.mat 10

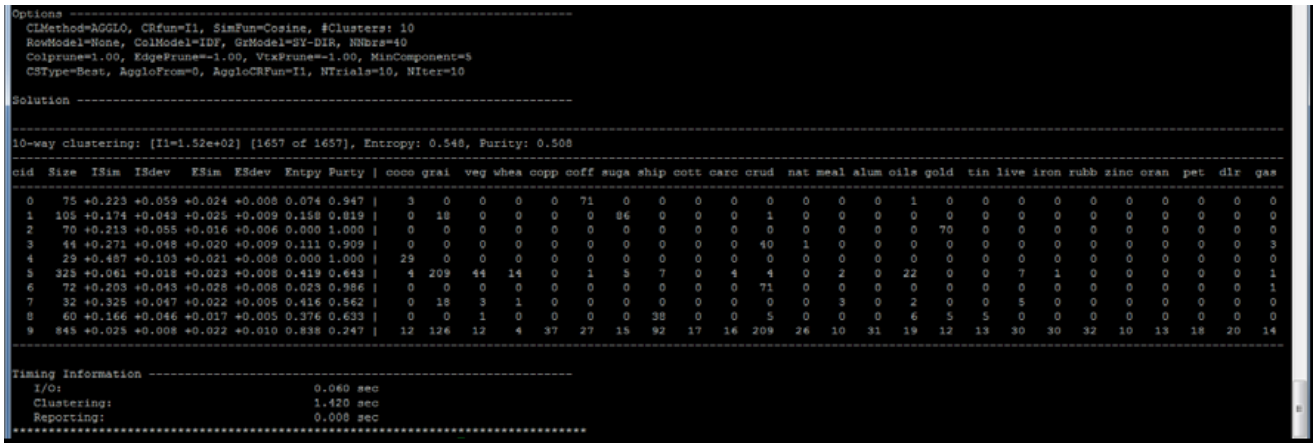

Tiene una pureza general de 0.508, es un algoritmo que consigue unas purezas medias un poco aleatorias, sin seguir un patrón fácil de explicar.

Con un algoritmo aglomerativo, función de similitud cosine y función de criterio i2

Línea de comando:

./vcluster -clmethod='agglo' -sim='cos' -crfun='i2' re1.mat 10

```
*******************************************************************************
vcluster (CLUTO 2.1.1) Copyright 2001-03, Regents of the University of Minnesota

Matrix Information ------------------------------------------------------------
  Name: re1.mat, #Rows: 1657, #Columns: 3758, #NonZeros: 87328

Options -----------------------------------------------------------------------
  CLMethod=AGGLO, CRfun=I2, SimFun=Cosine, #Clusters: 10
  RowModel=None, ColModel=IDF, GrModel=SY-DIR, NNbrs=40
  Colprune=1.00, EdgePrune=-1.00, VtxPrune=-1.00, MinComponent=5
  CSType=Best, AggloFrom=0, AggloCRFun=I2, NTrials=10, NIter=10

Solution ----------------------------------------------------------------------

------------------------------------------------------------------------
10-way clustering: [I2=4.64e+02] [1657 of 1657]
------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  |
------------------------------------------------------------------------
  0   204 +0.049 +0.018 +0.016 +0.006 |
  1   276 +0.039 +0.013 +0.022 +0.009 |
  2   155 +0.074 +0.038 +0.019 +0.008 |
  3   392 +0.055 +0.020 +0.021 +0.008 |
  4    64 +0.234 +0.054 +0.017 +0.007 |
  5   120 +0.152 +0.045 +0.025 +0.008 |
  6    82 +0.203 +0.060 +0.023 +0.008 |
  7   180 +0.070 +0.025 +0.022 +0.008 |
  8    78 +0.151 +0.060 +0.019 +0.008 |
  9   106 +0.129 +0.048 +0.025 +0.008 |
------------------------------------------------------------------------

Timing Information ------------------------------------------------------------
   I/O:                                 0.072 sec
   Clustering:                          1.476 sec
   Reporting:                           0.012 sec
*******************************************************************************
```

Aplicando la siguiente línea de comando:

./vcluster -clmethod='agglo' -sim='cos' -crfun='i2' -rclassfile=estadisticas/re1.mat.rclass re1.mat 10

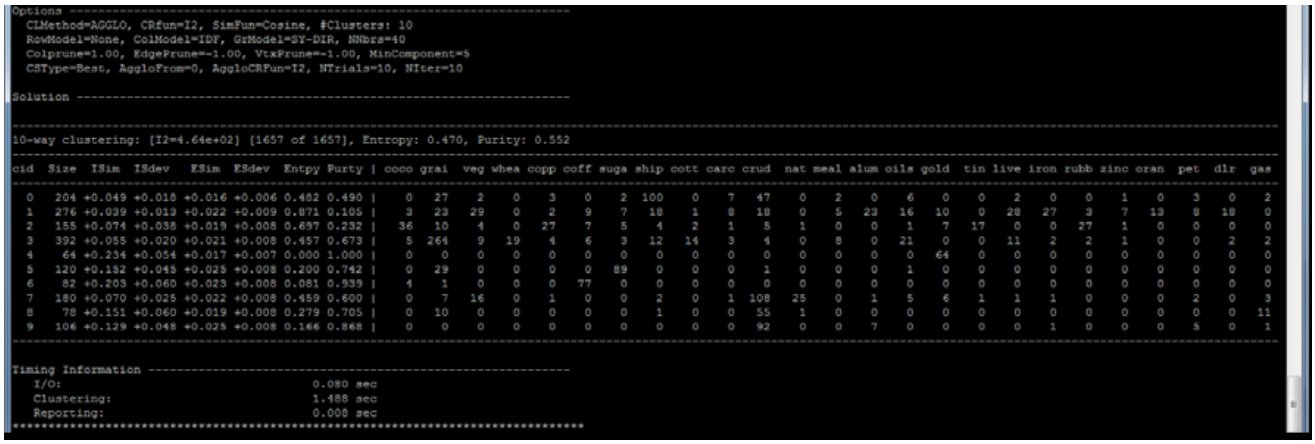

```
Options ----------------------------------------------------------------------
  CLMethod=AGGLO, CRfun=I2, SimFun=Cosine, #Clusters: 10
  RowModel=None, ColModel=IDF, GrModel=SY-DIR, NNbrs=40
  Colprune=1.00, EdgePrune=-1.00, VtxPrune=-1.00, MinComponent=5
  CSType=Best, AggloFrom=0, AggloCRFun=I2, NTrials=10, NIter=10

Solution ---------------------------------------------------------------------

------------------------------------------------------------------------------------------------------------------------------------------------
10-way clustering: [I2=4.64e+02] [1657 of 1657], Entropy: 0.470, Purity: 0.552
------------------------------------------------------------------------------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  Entpy Purty | coco grai  veg whea copp coff suga ship cott carc crud  nat meal alum oils gold  tin live iron rubb zinc oran  pet  dlr  gas
------------------------------------------------------------------------------------------------------------------------------------------------
  0   204 +0.049 +0.018 +0.016 +0.006 0.482 0.490 |    0   27    2    0    3    0    2  100    0    7   47    0    2    0    6    0    0    2    0    0    1    0    3    0    2
  1   276 +0.039 +0.013 +0.022 +0.009 0.871 0.105 |    3   23   29    0    2    9    7   18    1    8   18    0    5   23   16   10    0   28   27    3    7   13    8   18    0
  2   155 +0.074 +0.038 +0.019 +0.008 0.697 0.232 |   36   10    4    0   27    7    5    4    2    1    5    1    0    0    1    7   17    0    0   27    1    0    0    0    0
  3   392 +0.055 +0.020 +0.021 +0.008 0.457 0.673 |    5  264    9   19    4    6    3   12   14    3    4    0    8    0   21    0    0   11    2    2    1    0    0    2    2
  4    64 +0.234 +0.054 +0.017 +0.007 0.000 1.000 |    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0   64    0    0    0    0    0    0    0    0    0
  5   120 +0.132 +0.045 +0.025 +0.008 0.200 0.742 |    0   29    0    0    0    0   89    0    0    0    1    0    0    0    1    0    0    0    0    0    0    0    0    0    0
  6    82 +0.203 +0.060 +0.025 +0.008 0.081 0.939 |    4    1    0    0    0   77    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
  7   180 +0.070 +0.025 +0.022 +0.008 0.459 0.600 |    0    7   16    0    1    0    0    2    0    1  108   25    0    1    5    6    1    1    1    0    0    0    2    0    3
  8    78 +0.151 +0.060 +0.019 +0.008 0.279 0.705 |    0   10    0    0    0    0    0    1    0    0   55    1    0    0    0    0    0    0    0    0    0    0    0    0   11
  9   106 +0.129 +0.048 +0.025 +0.008 0.166 0.868 |    0    0    0    0    0    0    0    0    0    0   92    0    0    7    0    0    0    0    1    0    0    0    5    0    1
------------------------------------------------------------------------------------------------------------------------------------------------

Timing Information -----------------------------------------------------------
   I/O:                          0.080 sec
   Clustering:                   1.488 sec
   Reporting:                    0.008 sec
******************************************************************************
```

Consigue una mejor pureza general, pero no se nota mucha diferencia al haber cambiado únicamente la función de criterio de i1 a i2.

Con un algoritmo de separación, función de similitud de distancia euclidea y función de criterio i1

Línea de comando:

./vcluster -clmethod='graph' -sim='dist' -crfun='i1' re0.mat 10

```
*******************************************************************************
vcluster (CLUTO 2.1.1) Copyright 2001-03, Regents of the University of Minnesota

Matrix Information ------------------------------------------------------------
  Name: re1.mat, #Rows: 1657, #Columns: 3758, #NonZeros: 87328

Options -----------------------------------------------------------------------
  CLMethod=GRAPH, CRfun=Cut, SimFun=EuclDist, #Clusters: 10
  RowModel=None, ColModel=IDF, GrModel=SY-DIR, NNbrs=40
  Colprune=1.00, EdgePrune=-1.00, VtxPrune=-1.00, MinComponent=5
  CSType=Best, AggloFrom=0, AggloCRFun=SLINK_W, NTrials=10, NIter=10

Solution ----------------------------------------------------------------------

------------------------------------------------------------------------
33-way clustering: [Cut=1.33e+03] [280 of 1657]
------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  |
------------------------------------------------------------------------
  0     8 +0.922 +0.107 +0.000 +0.000 |
  1     5 +0.999 +0.000 +0.000 +0.000 |
  2     4 +0.988 +0.002 +0.001 +0.002 |
  3     5 +0.874 +0.131 +0.000 +0.000 |
  4     7 +0.789 +0.173 +0.000 +0.000 |
  5     7 +0.752 +0.187 +0.000 +0.000 |
  6     4 +0.808 +0.186 +0.001 +0.002 |
  7    45 +0.622 +0.273 +0.018 +0.016 |
  8    10 +0.643 +0.168 +0.003 +0.004 |
  9     5 +0.719 +0.014 +0.000 +0.000 |
 10     5 +0.696 +0.273 +0.000 +0.000 |
 11     8 +0.633 +0.185 +0.000 +0.000 |
 12     5 +0.661 +0.259 +0.000 +0.000 |
 13     5 +0.654 +0.252 +0.000 +0.000 |
 14    23 +0.555 +0.224 +0.014 +0.017 |
 15     4 +0.653 +0.267 +0.002 +0.003 |
 16     4 +0.648 +0.265 +0.006 +0.006 |
 17     6 +0.573 +0.208 +0.000 +0.000 |
 18     5 +0.590 +0.221 +0.000 +0.000 |
 19     5 +0.585 +0.279 +0.001 +0.002 |
 20     8 +0.532 +0.196 +0.000 +0.000 |
 21    10 +0.532 +0.271 +0.033 +0.018 |
 22    11 +0.486 +0.230 +0.001 +0.002 |
 23     8 +0.487 +0.235 +0.000 +0.000 |
 24     5 +0.521 +0.196 +0.000 +0.000 |
 25    11 +0.430 +0.180 +0.000 +0.000 |
 26     4 +0.518 +0.137 +0.001 +0.002 |
 27     6 +0.461 +0.203 +0.000 +0.000 |
 28     5 +0.383 +0.214 +0.000 +0.000 |
 29     9 +0.324 +0.161 +0.001 +0.002 |
 30     8 +0.315 +0.194 +0.000 +0.000 |
 31    16 +0.249 +0.156 +0.004 +0.006 |
 32     9 +0.202 +0.084 +0.000 +0.000 |
------------------------------------------------------------------------

Timing Information ------------------------------------------------------
   I/O:                          0.068 sec
   Clustering:                   0.244 sec
   Reporting:                    0.004 sec
*******************************************************************************
```

Comando:

./vcluster -clmethod='graph' -sim='dist' -crfun='i1' -rclassfile=estadisticas/re1.mat.rclass re1.mat 10

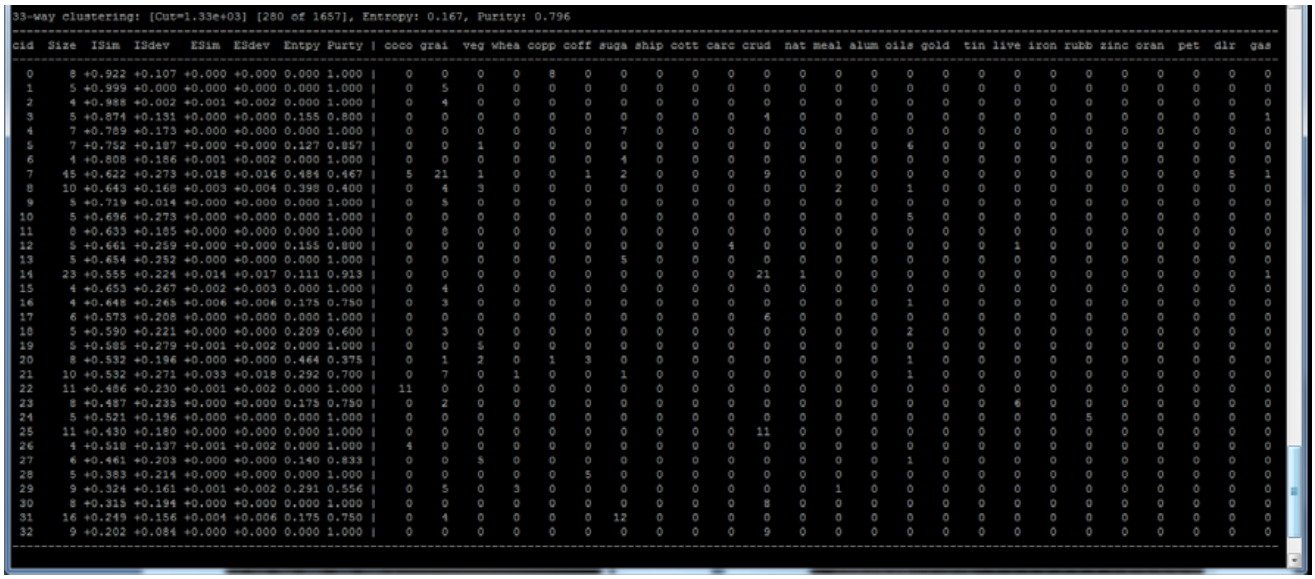

```
33-way clustering: [Cut=1.33e+03] [280 of 1657], Entropy: 0.167, Purity: 0.796
--------------------------------------------------------------------------------------------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  Entpy Purty | coco grai  veg whea copp coff suga ship cott carc crud  nat meal alum oils gold  tin live iron rubb zinc oran  pet  dlr  gas
--------------------------------------------------------------------------------------------------------------------------------------------------------------
  0     8 +0.922 +0.107 +0.000 +0.000 0.000 1.000 |    0    0    0    8    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
  1     5 +0.999 +0.000 +0.000 +0.000 0.000 1.000 |    0    5    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
  2     4 +0.988 +0.002 +0.001 +0.002 0.000 1.000 |    0    4    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
  3     5 +0.874 +0.131 +0.000 +0.000 0.155 0.800 |    0    0    0    0    0    0    0    0    0    0    0    4    0    0    0    0    0    0    0    0    0    0    0    0    1
  4     7 +0.789 +0.173 +0.000 +0.000 0.000 1.000 |    0    0    0    0    0    0    7    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
  5     7 +0.752 +0.187 +0.000 +0.000 0.127 0.857 |    0    0    1    0    0    0    0    0    0    0    0    0    0    0    0    6    0    0    0    0    0    0    0    0    0
  6     4 +0.808 +0.186 +0.001 +0.002 0.000 1.000 |    0    0    0    0    0    0    4    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
  7    45 +0.622 +0.273 +0.018 +0.016 0.484 0.467 |    5   21    1    0    0    1    2    0    0    0    9    0    0    0    0    0    0    0    0    0    0    0    0    5    1
  8    10 +0.643 +0.168 +0.003 +0.004 0.398 0.400 |    0    4    3    0    0    0    0    0    0    0    0    0    2    0    1    0    0    0    0    0    0    0    0    0    0
  9     5 +0.719 +0.014 +0.000 +0.000 0.000 1.000 |    0    5    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
 10     5 +0.696 +0.273 +0.000 +0.000 0.000 1.000 |    0    0    0    0    0    0    0    0    0    0    0    0    0    0    5    0    0    0    0    0    0    0    0    0    0
 11     8 +0.633 +0.185 +0.000 +0.000 0.000 1.000 |    0    8    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
 12     5 +0.661 +0.259 +0.000 +0.000 0.155 0.800 |    0    0    0    0    0    0    0    0    0    0    4    0    0    0    0    0    0    1    0    0    0    0    0    0    0
 13     5 +0.654 +0.252 +0.000 +0.000 0.000 1.000 |    0    0    0    0    0    0    5    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
 14    23 +0.555 +0.224 +0.014 +0.017 0.111 0.913 |    0    0    0    0    0    0    0    0    0    0    0   21    1    0    0    0    0    0    0    0    0    0    0    0    1
 15     4 +0.653 +0.267 +0.002 +0.003 0.000 1.000 |    0    4    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
 16     4 +0.648 +0.265 +0.006 +0.006 0.175 0.750 |    0    3    0    0    0    0    0    0    0    0    0    0    0    0    1    0    0    0    0    0    0    0    0    0    0
 17     6 +0.573 +0.208 +0.000 +0.000 0.000 1.000 |    0    0    0    0    0    0    0    0    0    0    6    0    0    0    0    0    0    0    0    0    0    0    0    0    0
 18     5 +0.590 +0.221 +0.000 +0.000 0.209 0.600 |    0    3    0    0    0    0    0    0    0    0    0    0    0    0    2    0    0    0    0    0    0    0    0    0    0
 19     5 +0.585 +0.279 +0.001 +0.002 0.000 1.000 |    0    0    5    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
 20     8 +0.532 +0.196 +0.000 +0.000 0.464 0.375 |    0    1    2    0    1    3    0    0    0    0    0    0    0    0    1    0    0    0    0    0    0    0    0    0    0
 21    10 +0.532 +0.271 +0.033 +0.018 0.292 0.700 |    0    7    0    1    0    0    1    0    0    0    0    0    0    0    1    0    0    0    0    0    0    0    0    0    0
 22    11 +0.486 +0.230 +0.001 +0.002 0.000 1.000 |   11    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
 23     8 +0.487 +0.235 +0.000 +0.000 0.175 0.750 |    0    2    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    6    0    0    0    0    0    0    0
 24     5 +0.521 +0.196 +0.000 +0.000 0.000 1.000 |    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    5    0    0    0    0    0
 25    11 +0.430 +0.180 +0.000 +0.000 0.000 1.000 |    0    0    0    0    0    0    0    0    0    0   11    0    0    0    0    0    0    0    0    0    0    0    0    0    0
 26     4 +0.518 +0.137 +0.001 +0.002 0.000 1.000 |    4    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
 27     6 +0.461 +0.203 +0.000 +0.000 0.140 0.833 |    0    0    5    0    0    0    0    0    0    0    0    0    0    0    1    0    0    0    0    0    0    0    0    0    0
 28     5 +0.383 +0.214 +0.000 +0.000 0.000 1.000 |    0    0    0    0    0    5    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
 29     9 +0.324 +0.161 +0.001 +0.002 0.291 0.556 |    0    5    0    3    0    0    0    0    0    0    0    0    1    0    0    0    0    0    0    0    0    0    0    0    0
 30     8 +0.315 +0.194 +0.000 +0.000 0.000 1.000 |    0    0    0    0    0    0    0    0    0    0    0    8    0    0    0    0    0    0    0    0    0    0    0    0    0
 31    16 +0.249 +0.156 +0.004 +0.006 0.175 0.750 |    0    4    0    0    0    0   12    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0    0
 32     9 +0.202 +0.084 +0.000 +0.000 0.000 1.000 |    0    0    0    0    0    0    0    0    0    0    0    9    0    0    0    0    0    0    0    0    0    0    0    0    0
--------------------------------------------------------------------------------------------------------------------------------------------------------------
```

En esta aplicación, se observa que el programa genera un mayor número de clústers, con un menor número de objetos almacenados en cada uno, pero con una pureza bastante alta, la media es de 0.796.

Esto indica que siguiendo un algoritmo de separación y una función de selección mediante distancia euclídea, se obtiene un mejor empaquetado mediante clustering.

Con un algoritmo de separación, función de similitud del coeficiente de Jaccard y función de criterio i1

Línea de comando:

./vcluster -clmethod='graph' -sim='jacc' -crfun='i1' re0.mat 10

```
*******************************************************************************
vcluster (CLUTO 2.1.1) Copyright 2001-03, Regents of the University of Minnesota

Matrix Information ------------------------------------------------------------
  Name: re1.mat, #Rows: 1657, #Columns: 3758, #NonZeros: 87328

Options -----------------------------------------------------------------------
  CLMethod=GRAPH, CRfun=Cut, SimFun=ExtJaccard, #Clusters: 10
  RowModel=None, ColModel=IDF, GrModel=SY-DIR, NNbrs=40
  Colprune=1.00, EdgePrune=-1.00, VtxPrune=-1.00, MinComponent=5
  CSType=Best, AggloFrom=0, AggloCRFun=SLINK_W, NTrials=10, NIter=10

Solution ----------------------------------------------------------------------

------------------------------------------------------------------------
10-way clustering: [Cut=3.17e+03] [1657 of 1657]
------------------------------------------------------------------------
cid  Size  ISim  ISdev   ESim  ESdev  |
------------------------------------------------------------------------
  0    90 +0.050 +0.027 +0.000 +0.000 |
  1    91 +0.049 +0.025 +0.000 +0.000 |
  2    90 +0.046 +0.034 +0.000 +0.000 |
  3   134 +0.030 +0.018 +0.000 +0.000 |
  4   148 +0.022 +0.018 +0.000 +0.000 |
  5   123 +0.020 +0.013 +0.000 +0.000 |
  6   168 +0.015 +0.010 +0.000 +0.000 |
  7   171 +0.015 +0.012 +0.001 +0.000 |
  8   244 +0.010 +0.006 +0.000 +0.000 |
  9   398 +0.009 +0.005 +0.000 +0.000 |
------------------------------------------------------------------------

Timing Information ------------------------------------------------------------
   I/O:                                    0.072 sec
   Clustering:                             0.716 sec
   Reporting:                              0.008 sec
*******************************************************************************
```

Comando:

./vcluster -clmethod='graph' -sim='jacc' -crfun='i1' -rclassfile=estadisticas/re1.mat.rclass

re1.mat 10

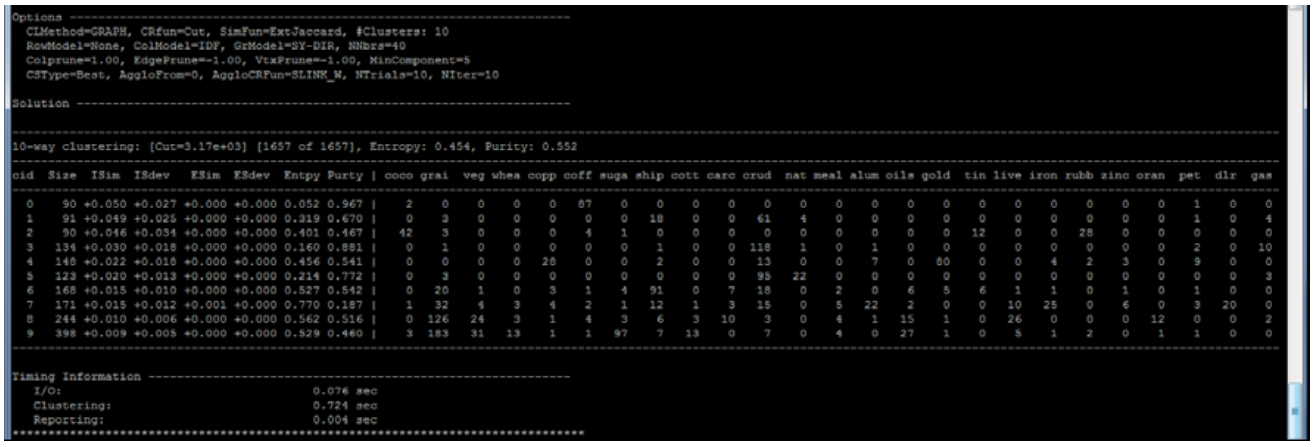

En esta aplicación, se observa que el programa genera los clústers con una pureza más alta y con un menor número de objetos insertados en los primeros clústeres, pero en los últimos clústers almacena

un mayor número de objetos y además de distinto tipo, haciendo que la pureza general sea peor que las anteriores.

Esto es producido por el cambio en la función de similitud.

Conclusiones generales sobre los distintos tipos de algoritmos a seguir.

Después de ver a las distintas salidas habiendo aplicado los distintos algoritmos, funciones de criterio y de selección, puedo observar lo siguiente:

- En la aplicación del algoritmo aglomerativo:
    - No existe una gran diferencia de empaquetado por clustering utilizando la función de criterio i1 o i2.
- En la aplicación del algoritmo de partición:
    - Cuando se aplica la función de similitud por distancia euclídea, se crea un mayor número de clusters y se consigue tener un mejor resultado.
    - Al aplicar la función de similitud por el coeficiente de Jaccard, se puede observar perfectamente cómo los primeros clusters tienen una mayor pureza y un menor número de objetos en su interior, pero casi todos del mismo tipo. Sin embargo, los clusters creados al final, tienen un mayor número de objetos dentro y un menor coeficiente de pureza.
- En general: el que mejor resultado ha dado sin duda es el algoritmo de partición con la aplicación de la función de similitud por distancia euclídea.